

机器学习驱动的 A 股多因子 Alpha 挖掘与回测研究

Machine Learning Alpha Research for A-Share Equity Returns

浙江大学统计学本科生量化研究项目

2026 年 5 月

摘要

本文构建了一个基于 AKShare 公开 A 股日频数据的 Machine Learning Alpha Research 框架。研究流程覆盖 AKShare 数据下载、股票池过滤、未来收益标签构造、36 个价量 Alpha 因子、横截面去极值与标准化、单因子 IC/RankIC 分析、Random Forest、XGBoost、LightGBM 与 PyTorch MLP 模型训练，以及样本外预测、分组回测、交易成本敏感性和稳健性分析。本次实验使用 2021–2024 年 98 只有效 A 股股票的前复权日频数据。结果显示，模型样本外 RankIC 为弱正，但在 2024 年测试区间内并未稳定跑赢等权股票池基准。本文强调严谨研究流程和风险披露，不将结果表述为稳定盈利策略。

1 Introduction

机器学习 Alpha Research 的核心目标，是在低信噪比的金融横截面数据中寻找可检验、可复现、可解释的弱预测信号。相比单纯报告一条收益曲线，一个合格的量化研究流程更应关注数据口径、标签定义、因子生成时点、样本外验证、交易成本和稳健性。

本文围绕如下问题展开：机器学习模型能否基于 A 股日频价量因子提取具有样本外稳定性的 Alpha 信号，并在考虑交易成本后改善横截面收益预测与组合回测表现？方法上，本文不直接追求复杂 Transformer，而是从 Random Forest、XGBoost、LightGBM 与简单 MLP 出发，因为日频 tabular alpha 数据通常噪声较高、维度有限，GBDT 类模型往往是更合理的强 baseline [3, 2, 4]。

2 Data and Preprocessing

数据来自 AKShare 公开 A 股日频接口。本次运行使用内置中等规模 A 股候选股票池 100 只，下

载 2021-01-04 至 2024-12-31 的前复权日频行情。最终 98 只股票下载成功，共 94,382 行数据，字段包括 date、code、open、high、low、close、volume、amount、turnover_rate 和由 outstanding shares 近似计算的 market_cap。

由于 AKShare 实时股票列表接口在本环境中不稳定，本文使用固定示例股票池并逐只下载历史数据。固定股票池可能带来股票池选择偏差或幸存者偏差，因此本文不把结果表述为完整全 A 实证结论。股票池过滤包括价格、成交量、成交额、最短历史长度和缺失比例检查。真实生产研究还应加入 ST 状态、上市天数、停牌、涨跌停、行业分类和可交易性约束。

3 Label Definition

主标签为未来 5 日收益：

$$y_{5d,t} = \frac{Open_{t+6}}{Open_{t+1}} - 1. \quad (1)$$

含义是在 t 日收盘后生成因子和模型分数，于 $t+1$ 日开盘买入，持有 5 个交易日，于 $t+6$ 日开盘卖出。项目同时生成 y_{1d} 、 y_{5d} 、 y_{10d} 与 y_{20d} ，用于持有期稳健性分析。

4 Alpha Factor Construction

本文构造 36 个基础价量因子，覆盖七类经济含义：动量/反转、波动率、流动性、量价关系、成交活跃度变化、价格位置和风险调整收益。所有 rolling 计算均按股票代码分组，且只使用 t 日及以前的信息。例如，短期反转由 ret_1、ret_3、ret_5 刻画；波动风险由 rolling return volatility 和 high-low amplitude 刻画；量价关系由 rolling correlation between return and volume/amount 刻画；成交活跃度变化由 5 日均值相对 20 日均值刻画。

5 Factor Preprocessing

每个交易日内对每个因子独立执行 1%/99% 分位数缩尾，随后做横截面 z-score。代码保留市值中性化接口：

$$factor_i = \alpha + \beta \log(MarketCap_i) + \epsilon_i. \quad (2)$$

但本次 AKShare 运行不启用市值中性化，因为前复权价格与 outstanding shares 近似得到的 market_cap 并不是严格的 point-in-time 风险模型口径。缺失值不会简单填 0；模型训练前删除缺失标签或缺失完整特征向量的样本。

6 Single Factor Analysis

单因子评价包括 Pearson IC、Spearman RankIC、ICIR、t-stat、胜率、因子相关矩阵和分组收益。RankIC 更关注横截面排序能力，因此比单纯 MSE 更贴近选股任务。本次 AKShare 运行中，RankIC 较高的因子包括 turnover_mean_20 等成交活跃度类指标。




图 1: 单因子 RankIC 均值




图 2: 最高 RankIC 因子的分组净值曲线

7 Machine Learning Models

Random Forest 作为 bagging-based nonlinear benchmark，用于检验普通非线性树模型是否能捕捉因子关系 [1]。XGBoost 是经典 boosting tree model，适合建模非线性和因子交互 [2]。LightGBM 是本文主力 GBDT 模型，适合较大规模 tabular panel data [4]。PyTorch MLP 是 simple deep learning baseline，结构为 128/64 hidden units、BatchNorm、ReLU 和 Dropout。

本文不将 MLP 或更复杂深度模型视为天然更优。日频价量因子通常噪声高、样本有效信息有限，MLP 容易过拟合，且缺少树模型对 tabular 特征切分的归纳偏置。因此模型比较重点放在样本外 RankIC、分组收益和交易成本后表现，而非训练集拟合误差。

表 1: 样本外预测指标 (AKShare test set)

Model	MSE	R^2	Daily IC	Daily RankIC
Random Forest	0.0037	-0.0042	0.0385	0.0258
XGBoost	0.0037	-0.0082	0.0305	0.0208
LightGBM	0.0038	-0.0162	0.0252	0.0245
MLP	0.0037	-0.0123	0.0304	0.0430

8 Backtesting Framework

回测规则为每 5 个交易日调仓一次，在调仓日 t 使用模型预测分数，选择分数最高的前 10% 股票，于 $t+1$ 开始等权持有 5 个交易日。benchmark 为股票池等权组合。默认单边交易成本为 10 bps，并额外测试 5、10、20 bps。评价指标包括年化收益、年化波动率、Sharpe、最大回撤、换手率和交易成本后收益。

9 Empirical Results

样本按时间切分：训练集为 2021-07-05 至 2023-08-01，验证集为 2023-08-02 至 2024-04-15，测试集为 2024-04-16 至 2024-12-23。表 2 展示 AKShare 测试集下的模型回测结果。等权 benchmark 的测试期年化收益为 0.3176；模型多头组合在该测试期没有稳定跑赢 benchmark，说明弱正 RankIC 不一定转化为交易成本后的超额收益。

表 2: 模型回测指标 (10 bps, AKShare test set)

Model	Annual Return	Annual Vol	Sharpe	Max DD	Turnover
Random Forest	0.2978	0.3461	0.9111	-0.1754	1.0353
XGBoost	0.2381	0.3135	0.8264	-0.1574	1.0647
LightGBM	0.1523	0.3160	0.5947	-0.1872	1.0941
MLP	0.2956	0.1820	1.5133	-0.0846	1.1882




图 3: 不同模型净值对比

可以看到，所有模型的样本外 R^2 均为负，但 RankIC 为弱正。这符合金融收益预测常见现象：点预测解释度很低并不必然否定横截面排序信息，但排序信息也不必然足以形成可交易超额收益。因此评价模型时，需要同时观察 RankIC、分组收益、交易成本后净值、换手和回撤。

10 Robustness Checks

稳健性分析覆盖不同交易成本、不同持有期和不同模型。交易成本上升会压缩净收益，说明组合换手和成本控制是 Alpha 能否落地的重要环节。

表 3: 交易成本敏感性 (LightGBM score, AKShare test set)

Cost bps	Annual Return	Sharpe	Max DD	Turnover
5.0000	0.1846	0.6825	-0.1793	1.0941
10.0000	0.1523	0.5947	-0.1872	1.0941
20.0000	0.0904	0.4195	-0.2029	1.0941




图 4: 交易成本敏感性

表 4: 持有期稳健性 (LightGBM score, AKShare test set)

Horizon	Annual Return	Sharpe	Max DD	Turnover
1d	0.0704	0.3687	-0.2015	0.6840
5d	0.1523	0.5947	-0.1872	1.0941
10d	0.3763	1.2149	-0.1467	1.3412
20d	0.4515	1.0652	-0.1528	1.4500

11 Avoiding Look-ahead Bias

本项目从以下方面控制未来信息泄露。第一，所有因子只使用 t 日及以前数据；第二，标签从 $t+1$ 开始计算，避免用当日无法成交的价格；第三，rolling 特征按股票分组并使用历史窗口；第四，去极值和标准化均在每个日期横截面内独立完成；第五，模型训练只使用过去数据预测未来数据；第六，不使用随机 train_test_split；第七，不使用缺少公告日期的财务数据；第八，固定股票池可能存在幸存者偏差；第九，测试集仅用于最终评估。

12 Limitations and Future Work

本文局限包括：AKShare 公共接口可能不稳定或字段变化；固定示例股票池不等于完整全 A point-in-time 股票池；交易成本假设简化，未考虑市场冲击成本；未加入真实高频订单簿；未进行严格行业中性化；未处理全部涨跌停、停牌和 ST 约束；未加入实盘验证；MLP 可能过拟合。后续可扩展至 point-in-time A 股真实数据、行业风险模型、组合优化、涨跌停约束、高频 LOB 特征、Temporal CNN 或 Transformer，但前提是数据口径和验证框架足够严格。

13 Conclusion

本文完成了一个从 AKShare 数据到因子、从模型到回测、从样本外验证到报告展示的 Machine Learning Alpha Research 框架。本次结果没有被包装成稳定盈利策略，而是展示了更真实的量化研究结论：机器学习模型可以提取弱排序信号，但交易成本、benchmark、换手和稳健性决定其是否具有进一步研究价值。

参考文献

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [2] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [3] Shihao Gu, Bryan Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5):2223–2273, 2020.
- [4] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, pages 3146–3154, 2017.