

# 机器学习驱动的 A 股多因子 Alpha 挖掘与回测研究

Machine Learning Alpha Research for A-Share Equity Returns

Independent Quantitative Research Project

2026 年 5 月

## 摘要

本文构建了一个基于 AKShare 公开 A 股日频数据的 Machine Learning Alpha Research 框架。研究流程覆盖 AKShare 数据下载、股票池过滤、未来收益标签构造、36 个价量 Alpha 因子、横截面去极值与标准化、单因子 IC/RankIC 分析、Random Forest、XGBoost、LightGBM 与 PyTorch MLP 模型训练，以及样本外预测、分组回测、交易成本敏感性和稳健性分析。本次实验使用 2021–2024 年 98 只有效 A 股股票的前复权日频数据。结果显示，模型样本外 RankIC 为弱正，但在 2024 年测试区间内并未稳定跑赢等权股票池基准。本文强调严谨研究流程和风险披露，不将结果表述为稳定盈利策略。

载 2021-01-04 至 2024-12-31 的前复权日频行情。最终 98 只股票下载成功，共 94,382 行数据，字段包括 date、code、open、high、low、close、volume、amount、turnover\_rate 和由 outstanding shares 近似计算的 market\_cap。

由于 AKShare 实时股票列表接口在本环境中不稳定，本文使用固定示例股票池并逐只下载历史数据。固定股票池可能带来股票池选择偏差或幸存者偏差，因此本文不把结果表述为完整全 A 实证结论。股票池过滤包括价格、成交量、成交额、最短历史长度和缺失比例检查。真实生产研究还应加入 ST 状态、上市天数、停牌、涨跌停、行业分类和可交易性约束。

## 1 Introduction

机器学习 Alpha Research 的核心目标，是在低信噪比的金融横截面数据中寻找可检验、可复现、可解释的弱预测信号。相比单纯报告一条收益曲线，一个合格的量化研究流程更应关注数据口径、标签定义、因子生成时点、样本外验证、交易成本和稳健性。

本文围绕如下问题展开：机器学习模型能否基于 A 股日频价量因子提取具有样本外稳定性的 Alpha 信号，并在考虑交易成本后改善横截面收益预测与组合回测表现？方法上，本文不直接追求复杂 Transformer，而是从 Random Forest、XGBoost、LightGBM 与简单 MLP 出发，因为日频 tabular alpha 数据通常噪声较高、维度有限，GBDT 类模型往往是更合理的强 baseline [3, 2, 4]。

## 2 Data and Preprocessing

数据来自 AKShare 公开 A 股日频接口。本次运行使用内置中等规模 A 股候选股票池 100 只，下

## 3 Label Definition

主标签为未来 5 日收益：

$$y_{5d,t} = \frac{Open_{t+6}}{Open_{t+1}} - 1. \quad (1)$$

含义是在  $t$  日收盘后生成因子和模型分数，于  $t+1$  日开盘买入，持有 5 个交易日，于  $t+6$  日开盘卖出。项目同时生成  $y_{1d}$ 、 $y_{5d}$ 、 $y_{10d}$  与  $y_{20d}$ ，用于持有期稳健性分析。

## 4 Alpha Factor Construction

本文构造 36 个基础价量因子，覆盖七类经济含义：动量/反转、波动率、流动性、量价关系、成交活跃度变化、价格位置和风险调整收益。所有 rolling 计算均按股票代码分组，且只使用  $t$  日及以前的信息。例如，短期反转由 ret\_1、ret\_3、ret\_5 刻画；波动风险由 rolling return volatility 和 high-low amplitude 刻画；量价关系由 rolling correlation between return and volume/amount 刻画；成交活跃度变化由 5 日均值相对 20 日均值刻画。

## 5 Factor Preprocessing

每个交易日内对每个因子独立执行 1%/99% 分位数缩尾，随后做横截面 z-score。代码保留市值中性化接口：

$$factor_i = \alpha + \beta \log(MarketCap_i) + \epsilon_i. \quad (2)$$

但本次 AKShare 运行不启用市值中性化，因为前复权价格与 outstanding shares 近似得到的 market\_cap 并不是严格的 point-in-time 风险模型口径。缺失值不会简单填 0；模型训练前删除缺失标签或缺失完整特征向量的样本。

## 6 Single Factor Analysis

单因子评价包括 Pearson IC、Spearman RankIC、ICIR、t-stat、胜率、因子相关矩阵和分组收益。RankIC 更关注横截面排序能力，因此比单纯 MSE 更贴近选股任务。本次 AKShare 运行中，RankIC 较高的因子包括 turnover\_mean\_20 等成交活跃度类指标。




图 1: 单因子 RankIC 均值




图 2: 最高 RankIC 因子的分组净值曲线

## 7 Machine Learning Models

Random Forest 作为 bagging-based nonlinear benchmark，用于检验普通非线性树模型是否能捕捉因子关系 [1]。XGBoost 是经典 boosting tree model，适合建模非线性和因子交互 [2]。LightGBM 是本文主力 GBDT 模型，适合较大规模 tabular panel data [4]。PyTorch MLP 是 simple deep learning baseline，结构为 128/64 hidden units、BatchNorm、ReLU 和 Dropout。

本文不将 MLP 或更复杂深度模型视为天然更优。日频价量因子通常噪声高、样本有效信息有限，MLP 容易过拟合，且缺少树模型对 tabular 特征切分的归纳偏置。因此模型比较重点放在样本外 RankIC、分组收益和交易成本后表现，而非训练集拟合误差。

表 1: 样本外预测指标 (AKShare test set)

| Model         | MSE    | $R^2$   | Daily IC | Daily RankIC |
|---------------|--------|---------|----------|--------------|
| Random Forest | 0.0037 | -0.0042 | 0.0385   | 0.0258       |
| XGBoost       | 0.0037 | -0.0082 | 0.0305   | 0.0208       |
| LightGBM      | 0.0038 | -0.0162 | 0.0252   | 0.0245       |
| MLP           | 0.0037 | -0.0123 | 0.0304   | 0.0430       |

## 8 Backtesting Framework

回测规则为每 5 个交易日调仓一次，在调仓日  $t$  使用模型预测分数，选择分数最高的前 10% 股票，于  $t+1$  开始等权持有 5 个交易日。benchmark 为股票池等权组合。默认单边交易成本为 10 bps，并额外测试 5、10、20 bps。评价指标包括年化收益、年化波动率、Sharpe、最大回撤、换手率和交易成本后收益。

## 9 Empirical Results

样本按时间切分：训练集为 2021-07-05 至 2023-08-01，验证集为 2023-08-02 至 2024-04-15，测试集为 2024-04-16 至 2024-12-23。表 2 展示 AKShare 测试集下的模型回测结果。等权 benchmark 的测试期年化收益为 0.3176；模型多头组合在该测试期没有稳定跑赢 benchmark，说明弱正 RankIC 不一定转化为交易成本后的超额收益。

表 2: 模型回测指标 (10 bps, AKShare test set)

| Model         | Annual Return | Annual Vol | Sharpe | Max DD  | Turnover |
|---------------|---------------|------------|--------|---------|----------|
| Random Forest | 0.2978        | 0.3461     | 0.9111 | -0.1754 | 1.0353   |
| XGBoost       | 0.2381        | 0.3135     | 0.8264 | -0.1574 | 1.0647   |
| LightGBM      | 0.1523        | 0.3160     | 0.5947 | -0.1872 | 1.0941   |
| MLP           | 0.2956        | 0.1820     | 1.5133 | -0.0846 | 1.1882   |




图 3: 不同模型净值对比

可以看到, 所有模型的样本外  $R^2$  均为负, 但 RankIC 为弱正。这符合金融收益预测常见现象: 点预测解释度很低并不必然否定横截面排序信息, 但排序信息也不必然足以形成可交易超额收益。因此评价模型时, 需要同时观察 RankIC、分组收益、交易成本后净值、换手和回撤。

## 10 Robustness Checks

稳健性分析覆盖不同交易成本、不同持有期和不同模型。交易成本上升会压缩净收益, 说明组合换手和成本控制是 Alpha 能否落地的重要环节。

表 3: 交易成本敏感性 (LightGBM score, AKShare test set)

| Cost bps | Annual Return | Sharpe | Max DD  | Turnover |
|----------|---------------|--------|---------|----------|
| 5.0000   | 0.1846        | 0.6825 | -0.1793 | 1.0941   |
| 10.0000  | 0.1523        | 0.5947 | -0.1872 | 1.0941   |
| 20.0000  | 0.0904        | 0.4195 | -0.2029 | 1.0941   |




图 4: 交易成本敏感性

表 4: 持有期稳健性 (LightGBM score, AKShare test set)

| Horizon | Annual Return | Sharpe | Max DD  | Turnover |
|---------|---------------|--------|---------|----------|
| 1d      | 0.0704        | 0.3687 | -0.2015 | 0.6840   |
| 5d      | 0.1523        | 0.5947 | -0.1872 | 1.0941   |
| 10d     | 0.3763        | 1.2149 | -0.1467 | 1.3412   |
| 20d     | 0.4515        | 1.0652 | -0.1528 | 1.4500   |

## 11 Avoiding Look-ahead Bias

本项目从以下方面控制未来信息泄露。第一, 所有因子只使用  $t$  日及以前数据; 第二, 标签从  $t+1$  开始计算, 避免用当日无法成交的价格; 第三, rolling 特征按股票分组并使用历史窗口; 第四, 去极值和标准化均在每个日期横截面内独立完成; 第五, 模型训练只使用过去数据预测未来数据; 第六, 不使用随机 train\_test\_split; 第七, 不使用缺少公告日期的财务数据; 第八, 固定股票池可能存在幸存者偏差; 第九, 测试集仅用于最终评估。

## 12 Limitations and Future Work

本文局限包括: AKShare 公共接口可能不稳定或字段变化; 固定示例股票池不等于完整全 A point-in-time 股票池; 交易成本假设简化, 未考虑市场冲击成本; 未加入真实高频订单簿; 未进行严格行业中性化; 未处理全部涨跌停、停牌和 ST 约束; 未加入实盘验证; MLP 可能过拟合。后续可扩展至 point-in-time A 股真实数据、行业风险模型、组合优化、涨跌停约束、高频 LOB 特征、Temporal CNN 或 Transformer, 但前提是数据口径和验证框架足够严格。

## 13 Conclusion

本文完成了一个从 AKShare 数据到因子、从模型到回测、从样本外验证到报告展示的 Machine Learning Alpha Research 框架。本次结果没有被包装成稳定盈利策略，而是展示了更真实的量化研究结论：机器学习模型可以提取弱排序信号，但交易成本、benchmark、换手和稳健性决定其是否具有进一步研究价值。

## 参考文献

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [2] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [3] Shihao Gu, Bryan Kelly, and Dacheng Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5):2223–2273, 2020.
- [4] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, pages 3146–3154, 2017.